Menganalisis Risiko Gagal Bayar Peminjam

Tugas pada data ini adalah menyiapkan laporan untuk divisi kredit suatu bank. Saya akan mencari tahu pengaruh status perkawinan seorang nasabah dan jumlah anak yang dimilikinya terhadap probabilitas gagal bayar dalam pelunasan pinjaman. Pihak bank sudah memiliki beberapa data mengenai kelayakan kredit nasabah.

Laporan saya akan dipertimbangkan pada saat membuat **penilaian kredit** untuk calon nasabah. **Penilaian kredit** digunakan untuk mengevaluasi kemampuan calon peminjam untuk melunasi pinjaman mereka.

Konten

- Pendahuluan
- Tahap 1. Ikhtisar Data
 - 1.1 Tujuan dan Tahapan
- Tahap 2. Buka file data dan baca informasi umumnya.
- Tahap 3. Eksplorasi data
- Tahap 4. Transformasi data
 - 4.1 Memperbaiki nilai yang hilang di total_income
 - 4.2 Memperbaiki nilai yang hilang di days_employed
- Tahap 5. Pengkategorian Data
- Tahap 6. Memeriksa hipotesis
- Kesimpulan

Pendahuluan:

Dalam penelitian kali ini, akan menganalisis risiko gagal bayar dari beberapa peminjam yang memiliki beberapa karakteristik sesuai dengan yang disajikan di dalam tabel. Untuk bisa mendapatkan karakteristik nasabah tersebut, maka akan menguji beberapa hipotesis yang didapat dari dalam tabel.

Tujuan dan Tahapan:

Tujuan dari pengolahan data kali ini akan menguji tiga hipotesis:

- 1. Nasabah dengan jumlah anak yang banyak memiliki resiko gagal pinjam sangat tinggi.
- 2. Nasabah dengan status married akan kesulitan dalam melakukan pembayaran tepat waktu.
- 3. Tingkat pendapatan yang rendah dari para nasabah akan mengakibatkan nasabah sulit membayar tepat waktu.

4. Tujuan peminjaman dana untuk kebutuhan tempat tinggal akan menyulitkan nasabah untuk membayar tepat waktu.

Data tentang nasabah yang melakukan peminjaman dana disimpan dalam berkas /datasets/credit_scoring_eng.csv . Sebelum melakukan uji hipotesis akan dilakukan observasi terhadap data untuk bisa menemukan apakah ada kesalahan dan kekurangan informasi yang ada didalam data tersebut.

Setelah melakukan observasi dan mendapatakan hal-hal yang perlu diperbaiki, isi data akan dikategorikan berdasarkan beberapa parameter yang dapat membantu untuk menguji apakah hipotesis di awal bisa diterima atau tidak.

Kembali ke Daftar Isi

Buka file data dan baca informasi umumnya.

[Mulailah dengan mengimpor *library* dan memuat datanya. Anda mungkin akan menyadari bahwa Anda memerlukan *library* tambahan saat Anda telah mengerjakan proyek ini, dan itu merupakan hal yang normal. Hanya saja, pastikan untuk memperbarui bagian ini jika dibutuhkan.]

```
In [1]: # Muat semua *Library*
import pandas as pd
import numpy as np
import seaborn as sns

import warnings
warnings.filterwarnings('ignore')
In [2]: # Muat datanya
df = pd.read_csv('/datasets/credit_scoring_eng.csv')
```

Soal 1. Eksplorasi data

Deskripsi Data

- children jumlah anak dalam keluarga
- days employed pengalaman kerja nasabah dalam hari
- dob_years usia nasabah dalam tahun
- education tingkat pendidikan nasabah
- education_id pengidentifikasi untuk tingkat pendidikan nasabah
- family_status pengidentifikasi untuk status perkawinan nasabah
- family_status_id tanda pengenal status perkawinan
- gender jenis kelamin nasabah
- income type jenis pekerjaan
- debt apakah nasabah memiliki hutang pembayaran pinjaman
- total income pendapatan bulanan

purpose - tujuan mendapatkan pinjaman

```
# Mari kita lihat berapa banyak baris dan kolom yang dimiliki oleh dataset kita
In [3]:
          df.shape
          (21525, 12)
Out[3]:
In [4]:
          # Mari tampilkan N baris pertama
          df.head()
Out[4]:
             children days_employed dob_years
                                                  education education_id family_status family_status_id gend
                                                  bachelor's
         0
                   1
                                                                       0
                                                                                married
                                                                                                      0
                        -8437.673028
                                             42
                                                     degree
                                                  secondary
          1
                         -4024.803754
                                             36
                                                                                married
                                                                                                      0
                   1
                                                                       1
                                                  education
                                                  Secondary
          2
                   0
                                                                       1
                                                                                                      0
                        -5623.422610
                                                                                married
                                                  Education
                                                  secondary
                                                                                                      0
         3
                   3
                                             32
                                                                       1
                                                                                married
                         -4124.747207
                                                  education
                                                  secondary
                                                                                   civil
          4
                       340266.072047
                                                                       1
                                                                                                      1
                                                  education
                                                                             partnership
```

Dari tampilan beberapa baris di awal tabel, terlihat beberapa keaneham seperti ada nilai minus di kolom 'days_employed' dan penggunaan huruf besar yang berbeda di kolom 'education'.

```
# Dapatkan informasi data
In [5]:
        df.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 21525 entries, 0 to 21524
        Data columns (total 12 columns):
         #
             Column
                               Non-Null Count
                                               Dtype
             _____
                               _____
         0
             children
                               21525 non-null int64
         1
             days_employed
                               19351 non-null float64
         2
             dob years
                               21525 non-null
                                               int64
         3
             education
                               21525 non-null object
         4
             education id
                               21525 non-null
                                               int64
         5
             family status
                               21525 non-null object
             family_status_id 21525 non-null int64
         6
         7
             gender
                               21525 non-null
                                               object
         8
             income_type
                               21525 non-null
                                               object
         9
             debt
                                               int64
                               21525 non-null
         10
             total income
                               19351 non-null
                                               float64
             purpose
                               21525 non-null
                                               object
        dtypes: float64(2), int64(5), object(5)
        memory usage: 2.0+ MB
        df.isna().sum()
```

In [6]:

Out[6]:	children	0
oucloj.	days_employed	2174
	dob_years	0
	education	0
	education_id	0
	family_status	0
	<pre>family_status_id</pre>	0
	gender	0
	income_type	0
	debt	0
	total_income	2174
	purpose	0
	dtype: int64	

In [7]: df.describe()

. . . .

Out	[7]	٠
000	L ' J	۰

	children	days_employed	dob_years	education_id	family_status_id	debt	to
count	21525.000000	19351.000000	21525.000000	21525.000000	21525.000000	21525.000000	19:
mean	0.538908	63046.497661	43.293380	0.817236	0.972544	0.080883	26
std	1.381587	140827.311974	12.574584	0.548138	1.420324	0.272661	164
min	-1.000000	-18388.949901	0.000000	0.000000	0.000000	0.000000	33
25%	0.000000	-2747.423625	33.000000	1.000000	0.000000	0.000000	164
50%	0.000000	-1203.369529	42.000000	1.000000	0.000000	0.000000	232
75%	1.000000	-291.095954	53.000000	1.000000	1.000000	0.000000	32!
max	20.000000	401755.400475	75.000000	4.000000	4.000000	1.000000	3624

Dari tabel describe di atas, kita bisa melihat persebaran data dari setiap kolom yang ada. Jumlah data sesuai dengan yang kita dapat melalui metode .info. Untuk nilai yang hilang pun jumlahnya sama pada kolom total_income dan days_employed. Serta disini kita juga bisa mengetahui banyak nilai negatif di kolom days_employed dan ada nilai yang aneh di kolom children dan dob_years.

Terdapat dua kolom dimana terdapat nilai yang hilang pada tabel tersebut. Kolom tersebut adalah 'days_employed' dan 'total_income'. Kedua kolom memiliki jumlah nilai yang hilang sebanyak 2174.

```
In [8]: # Mari kita lihat tabel yang difilter dengan nilai yang hilang di kolom pertama yang n
df[df['days_employed'].isna()]
```

Out[8]:		children	days_employed	dob_years	education	education_id	family_status	family_status_id
	12	0	NaN	65	secondary education	1	civil partnership	1
	26	0	NaN	41	secondary education	1	married	0
	29	0	NaN	63	secondary education	1	unmarried	4
	41	0	NaN	50	secondary education	1	married	0
	55	0	NaN	54	secondary education	1	civil partnership	1
	•••							
	21489	2	NaN	47	Secondary Education	1	married	0
	21495	1	NaN	50	secondary education	1	civil partnership	1
	21497	0	NaN	48	BACHELOR'S DEGREE	0	married	0
	21502	1	NaN	42	secondary education	1	married	0
	21510	2	NaN	28	secondary education	1	married	0
	2174 ro	ws × 12 c	columns					

Nilai yang hilang tampak simetris karena jumlahnya sama untuk kolom 'days_employed' dan 'total income' yaitu sebanyak 2174 nilai yang hilang

```
In [9]: # Menerapkan beberapa kondisi untuk memfilter data dan melihat jumlah baris dalam tabé
df_clean = df.dropna()

df_clean
```

Out[9]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id
C) 1	-8437.673028	42	bachelor's degree	0	married	0
1	i 1	-4024.803754	36	secondary education	1	married	0
2	0	-5623.422610	33	Secondary Education	1	married	0
3	3	-4124.747207	32	secondary education	1	married	0
4	0	340266.072047	53	secondary education	1	civil partnership	1
••	•						
21520	1	-4529.316663	43	secondary education	1	civil partnership	1
21521	0	343937.404131	67	secondary education	1	married	0
21522	2 1	-2113.346888	38	secondary education	1	civil partnership	1
21523	3	-3112.481705	38	secondary education	1	married	0
21524	1 2	-1984.507589	40	secondary education	1	married	0

19351 rows × 12 columns

```
In [10]: total_missing = df['total_income'].isna().sum()
    percent_missing = total_missing / len(df) *100
    percent_missing
```

Out[10]: 10.099883855981417

Jumlah baris yang hilang sesuai dengan hasil filter tabel untuk nilai yag hilang, sehingga bisa disimpulkan bahwa baris dimana terdapat nilai yang hilang di kolom 'days_employed' juga akan memiliki nilai yang hilang di kolom 'total_income'.

Persentase nilai yang hilang pada tabel adalah sebesar 10.099% dan terbilang tidak cukup besar tetapi mungkin bisa mempengaruhi hasil analisa dari tabel. Karena itu diperlukan untuk mengisi nilai-nilai yang hilang untuk bisa mendapatkan analisa yang baik.

Langkah selanjutnya adalah mengisi nilai yang hilang dengan nilai rata-rata (mean) atau dengan nilai tengah (median) bergantung dari outlier yang terlihat dari tabel.

```
In [11]: # Mari kita periksa nasabah yang tidak memiliki data tentang karakteristik yang teride
df_null = df[(df['days_employed'].isna()) & (df['total_income'].isna())].reset_index(delian)
```

```
print(df null['income type'].nunique())
          print(df null['income type'].unique())
          print(df null['income type'].value counts(normalize=True))
         ['retiree' 'civil servant' 'business' 'employee' 'entrepreneur']
                          0.508280
         employee
         business
                          0.233671
         retiree
                          0.189972
         civil servant 0.067617
         entrepreneur
                          0.000460
         Name: income_type, dtype: float64
         # Periksalah distribusinya
In [12]:
         print(df_null['education'].nunique())
          print(df null['education'].unique())
         print(df_null['education'].value_counts(normalize=True))
         ['secondary education' "bachelor's degree" 'SECONDARY EDUCATION'
           'some college' 'Secondary Education' 'Some College' "Bachelor's Degree"
          'SOME COLLEGE' 'primary education' "BACHELOR'S DEGREE"
          'Primary Education' 'PRIMARY EDUCATION']
         secondary education
                                0.647654
         bachelor's degree
                                0.228151
         SECONDARY EDUCATION
                                0.030819
         Secondary Education
                                0.029899
         some college
                                0.025299
         Bachelor's Degree
BACHELOR'S DEGREE
primary education
                                0.011500
                                0.010580
                                0.008740
         SOME COLLEGE
                                0.003220
         Some College
PRIMARY EDUCATION
                                0.003220
                                0.000460
         Primary Education
                                0.000460
         Name: education, dtype: float64
         print(df_null['family_status'].nunique())
In [13]:
          print(df null['family status'].unique())
         print(df null['family status'].value counts(normalize=True))
         ['civil partnership' 'married' 'unmarried' 'widow / widower' 'divorced']
         married
                              0.568997
         civil partnership
                              0.203312
         unmarried
                              0.132475
         divorced
                              0.051518
         widow / widower
                              0.043698
         Name: family_status, dtype: float64
```

Melihat tabel dengan nilai yang hilang hanya diisi oleh beberapa kategori saja jika dibandingkan dengan tabel keseluruhan, dimana nilai yang hilang jika dilihat dari tabel income_type hanya berisi 5 nilai unique, berbeda dengan tabel keseluruhan yang memiliki 8 nilai unique. Nilai yang tidak terdappat pada tabel yang hilang seperti retiree, paternity/maternity leave, dan student. Lalu didapat juga perbedaan pada kolom education, tapi perbedaan belum bisa terlihat secara jelas mengingat nilai pada kolom ini memiliki nilai perbedaan penggunaan huruf yang mengakibatkan adanya duplikasi.

```
In [14]: # Memeriksa distribusi di seluruh *dataset*
          print(df['income type'].nunique())
          print(df['income type'].unique())
         print(df['income_type'].value_counts(normalize=True))
         8
         ['employee' 'retiree' 'business' 'civil servant' 'unemployed'
           'entrepreneur' 'student' 'paternity / maternity leave']
         employee
                                        0.516562
         business
                                        0.236237
         retiree
                                        0.179141
         civil servant
                                        0.067782
         unemployed
                                        0.000093
         entrepreneur
                                        0.000093
         paternity / maternity leave
                                        0.000046
                                        0.000046
         student
         Name: income type, dtype: float64
In [15]:
         print(df['education'].nunique())
         print(df['education'].unique())
          print(df['education'].value_counts(normalize=True))
         ["bachelor's degree" 'secondary education' 'Secondary Education'
           'SECONDARY EDUCATION' "BACHELOR'S DEGREE" 'some college'
           'primary education' "Bachelor's Degree" 'SOME COLLEGE' 'Some College'
          'PRIMARY EDUCATION' 'Primary Education' 'Graduate Degree'
          'GRADUATE DEGREE' 'graduate degree']
         secondary education 0.638792
         bachelor's degree
                                0.219187
         SECONDARY EDUCATION
                                0.035865
         Secondary Education
                                0.033031
         some college
                                0.031034
         BACHELOR'S DEGREE
                                0.012729
         Bachelor's Degree
                                0.012451
         primary education
                                0.011614
         Some College
                                0.002184
         SOME COLLEGE
                                0.001347
         PRIMARY EDUCATION
                                0.000790
         Primary Education
                                0.000697
         graduate degree
                                0.000186
         GRADUATE DEGREE
                                0.000046
         Graduate Degree
                                0.000046
         Name: education, dtype: float64
In [16]:
         print(df['family_status'].nunique())
         print(df['family status'].unique())
         print(df['family status'].value counts(normalize=True))
         ['married' 'civil partnership' 'widow / widower' 'divorced' 'unmarried']
         married
                              0.575145
         civil partnership
                              0.194053
         unmarried
                              0.130685
         divorced
                              0.055517
         widow / widower
                              0.044599
         Name: family_status, dtype: float64
```

Dari hasil observasi, untuk nilai yang hilang didominasi oleh income_type employee, sama seperti dengan tabel keseluruhan. Hal yang sama didapat jika melihat kolom family_status

dimana keduanya didominasi oleh family_status married.

```
# Periksa penyebab dan pola lain yang dapat mengakibatkan nilai yang hilang
In [17]:
          df null[df null['income type']=='employee']['children'].value counts(normalize=True)
                 0.589140
Out[17]:
          1
                 0.252489
          2
                 0.123982
          3
                0.026244
          4
                0.003620
          20
                0.002715
          5
                 0.000905
          -1
                 0.000905
         Name: children, dtype: float64
         df[df['income type']=='employee']['debt'].value counts(normalize=True)
In [18]:
               0.904578
Out[18]:
         1
               0.095422
         Name: debt, dtype: float64
```

Nilai yang hilang kemungkinan besar didominasi oleh nasabah dengan status income_type employee dan family_status married

Pola yang terlihat kebanyakan dari nilai yang hilang memang diperoleh dari income_type employee dan family_status married, ini bisa menandakan bahwa nasabah dengan status tersebut paling banyak melakukan kesalahan dalam pengisian data yang mengakibatkan adanya data yang hilang.

Untuk nilai yang hilang akan diisi menggunakan median atau mean dari kolom tersebut sesuai dengan kelompok dari income_type nya. Penentuan dari median atau mean yang akan digunakan bergantung dari outlier yang didapat dalam kolom total_income.

Pada transformasi data akan dilakukan observasi pada nilai-nilai yang ada didalam kolom:

- apakah ada kesalahan pengetikan (huruf besar dan kecil dengan kata yang sama), jika ada maka akan disamakan karakter penulisannya
- nilai yang terlihat aneh(adanya tanda minus pada beberapa kolom), nilai yang minus akan diubah ke positif
- nilai yang hilang pada beberapa kolom akan diisi dengan menggunakan nilai median atau nilai rata-rata dalam kolom tersebut
- duplikat yang terdapat pada tabel akan dihilangkan

Transformasi data

Dalam kolom education terdapat beberapa duplikasi kata. Duplikasi disebabkan huruf yang digunakan untuk penulisan tidak seragam, ada yang menggunakan upper case pada penulisannya. Untuk bisa mengatasi hal tersebut, keseluruhan isi didalam kolom education akan diubah menjadi lower case.

```
# Periksa semua nilai di kolom untuk memastikan bahwa kita telah memperbaikinya dengan
In [22]:
          print(sorted(df['education'].unique()))
          print(sorted(df['family_status'].unique()))
          print(sorted(df['income type'].unique()))
          print(sorted(df['gender'].unique()))
          print(sorted(df['purpose'].unique()))
          ["bachelor's degree", 'graduate degree', 'primary education', 'secondary education',
          'some college']
         ['civil partnership', 'divorced', 'married', 'unmarried', 'widow / widower']
         ['business', 'civil servant', 'employee', 'entrepreneur', 'paternity / maternity leav
         e', 'retiree', 'student', 'unemployed']
         ['F', 'M', 'XNA']
         ['building a property', 'building a real estate', 'buy commercial real estate', 'buy
         real estate', 'buy residential real estate', 'buying a second-hand car', 'buying my o
         wn car', 'buying property for renting out', 'car', 'car purchase', 'cars', 'construct
         ion of own property', 'education', 'getting an education', 'getting higher educatio
         n', 'going to university', 'having a wedding', 'housing', 'housing renovation', 'hous
         ing transactions', 'profile education', 'property', 'purchase of a car', 'purchase of
         my own house', 'purchase of the house', 'purchase of the house for my family', 'real
         estate transactions', 'second-hand car purchase', 'supplementary education', 'to beco
         me educated', 'to buy a car', 'to get a supplementary education', 'to have a weddin
         g', 'to own a car', 'transactions with commercial real estate', 'transactions with my
```

```
In [23]: # Mari kita lihat distribusi nilai pada kolom `children`
print(df['children'].unique())

[ 1 0 3 2 -1 4 20 5]
```

real estate', 'university education', 'wedding ceremony']

Terdapat nilai -1 pada kolom 'children', yang bisa disebabkan oleh human error ketika proses input data. Pada kasus ini, nilai -1 akan diubah menjadi 1. Selain itu terdapat nilai 20 yang terlihat sangat aneh untuk memiliki anak sebanyak 20, maka nilai 20 akan diganti menjadi 2.

```
In [24]: # [perbaiki data berdasarkan keputusan Anda]
    df.loc[df['children'] == -1, 'children'] = 1
    df.loc[df['children'] == 20, 'children'] = 2
```

```
In [25]: # Periksa kembali kolom `children` untuk memastikan bahwa semuanya telah diperbaiki
print(df['children'].unique())
[1 0 3 2 4 5]
```

Terdapat nilai - (minus) pada kolom 'days_employed'. Hal ini akan sangat berpengaruh mengingat pada kolom ini juga terdapat nilai yang hilang. Nilai minus ini akan berpengaruh ketika kita akan menentukan mean atau median dari kolom tersebut. Untuk itu nilai minus akan diubah k arah positif/mutlak.

```
# Temukan data yang bermasalah di `days employed`
In [26]:
          df['days employed'].describe()
          df.loc[df['days_employed'] < 0].count()</pre>
         children
                              15906
Out[26]:
         days_employed
                              15906
         dob years
                              15906
         education
                              15906
         education id
                             15906
         family status
                              15906
         family_status_id
                              15906
         gender
                              15906
         income type
                              15906
         debt
                              15906
         total income
                              15906
                              15906
         purpose
         dtype: int64
         days_error = df[df['days_employed'] < 0].count()</pre>
In [27]:
          percent_days_error = days_error / len(df) *100
          print(percent days error)
         children
                              73.89547
         days employed
                              73.89547
         dob years
                              73.89547
         education
                              73.89547
         education id
                              73.89547
         family status
                             73.89547
         family_status_id
                             73.89547
         gender
                              73.89547
         income_type
                              73.89547
         debt
                              73.89547
         total income
                              73.89547
         purpose
                              73.89547
         dtype: float64
```

Data yang error ada 73.72% dari total data, sehingga jika menghapus data akan merusak analisis. Hal yang paling mungkin adalah memperbaiki data, dimana jika dilihat dari distribusinya terdapat nilai - (minus) pada kolom 'days_employed'. Maka dari itu nilai minus akan diubah ke positif agar data dapat diolah lebih lanjut untuk analisis.

```
In [28]: # Atasi nilai yang bermasalah
days_employed = df['days_employed']

for days in days_employed:
```

```
if days < 0:</pre>
                   df['days employed'] = df['days employed'].replace(days, days * -1)
          print(df[df['days_employed'] < 0].count())</pre>
          children
                               0
          days_employed
                               0
          dob years
                               0
          education
                               0
          education id
                               0
          family_status
          family_status_id
          gender
                               0
          income type
                               0
          debt
                               0
          total_income
                               0
          purpose
                               0
          dtype: int64
In [29]: # Periksa hasilnya - pastikan bahwa masalahnya telah diperbaiki
          df['days_employed'].describe()
                    19351.000000
          count
Out[29]:
          mean
                    66914.728907
                   139030.880527
          std
                        24.141633
          min
          25%
                      927.009265
          50%
                     2194.220567
          75%
                     5537.882441
                   401755.400475
          max
          Name: days employed, dtype: float64
In [30]: df['dob_years'].describe()
          df[df['dob years'] == 0].count()
          children
                               101
Out[30]:
          days employed
                                91
          dob years
                               101
          education
                               101
          education_id
                               101
          family_status
                               101
          family status id
                               101
          gender
                               101
          income type
                               101
          debt
                               101
          total income
                                91
          purpose
                               101
          dtype: int64
          Dari distribusi terlihat ada nilai 0 untuk 'dob_years'. Ini sangat tidak masuk akal karena tidak
          mungkin usia dari nasabah adalah 0.
```

```
In [31]: # Periksa `dob_years` untuk nilai yang mencurigakan dan hitung persentasenya
df['dob_years'].describe()

dob_error = df[df['dob_years'] == 0].count()

percent_dob_error = dob_error / len(df) *100
```

```
print(percent_dob_error)
children
                    0.469222
days_employed
                    0.422764
dob_years
                    0.469222
education
                    0.469222
education id
                    0.469222
family status
                    0.469222
family_status_id
                    0.469222
gender
                    0.469222
income_type
                    0.469222
debt
                    0.469222
total income
                    0.422764
                    0.469222
purpose
dtype: float64
```

Pada kolom 'dob_years', persentase errornya adalah sebesar 0.47%. Melihat dari kecilnya error, data tersebut bisa saja dihapus agar analisis yang dibuat bisa ebih baik, selain itu bisa juga dengan memberikan nilai mean atau median bergantung pada outlier data yang terlihat.

```
In [32]: # Atasi masalah pada kolom `dob_years`
    df.loc[df['dob_years'] == 0]
```

Out[32]:		children	days_employed	dob_years	education	education_id	family_status	family_status_id
	99	0	346541.618895	0	secondary education	1	married	0
	149	0	2664.273168	0	secondary education	1	divorced	3
	270	3	1872.663186	0	secondary education	1	married	0
	578	0	397856.565013	0	secondary education	1	married	0
	1040	0	1158.029561	0	bachelor's degree	0	divorced	3
	•••							
	19829	0	NaN	0	secondary education	1	married	0
	20462	0	338734.868540	0	secondary education	1	married	0
	20577	0	331741.271455	0	secondary education	1	unmarried	4
	21179	2	108.967042	0	bachelor's degree	0	married	0
	21313	0	1268.487728	0	secondary education	1	unmarried	4

101 rows × 12 columns

```
dob mean = df['dob years'].mean()
In [33]:
          print(dob mean)
         dob_median = df['dob_years'].median()
          print(dob median)
         43.29337979094077
         42.0
         df.loc[df['dob_years'] == 0, 'dob_years'] = dob_median
In [34]:
In [35]: # Periksa hasilnya - pastikan bahwa masalahnya telah diperbaiki
         df['dob years'].describe()
         count
                  21525.000000
Out[35]:
                     43.490453
         mean
                     12.218595
         std
         min
                     19.000000
         25%
                     34.000000
         50%
                     42.000000
         75%
                     53.000000
                     75.000000
         max
         Name: dob years, dtype: float64
         # Mari kita lihat nilai untuk kolom ini
In [36]:
         print(df['family status'].unique())
         ['married' 'civil partnership' 'widow / widower' 'divorced' 'unmarried']
         Tidak ada maslah untuk kolom family_status
         # Mari kita liat nilai dalam kolom gender
In [39]:
         print(df['gender'].unique())
         ['F' 'M' 'XNA']
In [40]:
         # Atasi nilai-nilai yang bermasalah
         print(df.loc[df['gender'] == 'XNA'])
                children days employed dob years
                                                        education education id \
         10701
                            2358.600502
                                               24.0 some college
                    family status family status id gender income type debt \
         10701 civil partnership
                                                        XNA
                                                               business
                total income
                                       purpose
         10701
                   32624.825 buy real estate
         df = df[df['gender'] != 'XNA' ].reset_index(drop=True)
In [41]:
In [42]: # Periksa hasilnya - pastikan bahwa masalahnya telah diperbaiki
         print(df['gender'].unique())
         ['F' 'M']
         # Mari kita lihat nilai dalam kolom income type
In [43]:
          print(df['income type'].unique())
```

```
['employee' 'retiree' 'business' 'civil servant' 'unemployed'
  'entrepreneur' 'student' 'paternity / maternity leave']
```

Tidak ada masalah pada isi dari kolom income_type.

Duplikat yang ditemukan dalam tabel akan dihilangkan dengan menggunakan metode drop_duplicates() agar data bisa dianalisis dengan baik.

Dataset baru memiliki jumlah baris sebanyak 21385, sedangkan data awal sebanyak 21525. Pda dataset yang baru untuk nilai-nilai pada kolom yang bermasalah sudah diperbaiki mulai dari karakter huruf yang berbeda, nilai yang memiliki tanda negatif, menghilangkan baris yang terdapat hasil 'unindetified', dan pengisian untuk nilai yang hilang. Dataset mengalami perubahan sebesar 0,65% dari dataset awal.

Bekerja dengan nilai yang hilang

Memperbaiki nilai yang hilang di total_income

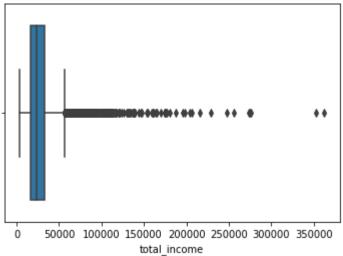
```
In [51]: # Mari kita tulis sebuah fungsi untuk menghitung kategori usia

def age_group (dob_years):
    if dob_years < 10:
        return 'children'</pre>
```

```
elif 10 <= dob years <= 19:
                    return 'teenager'
               elif 20 <= dob_years <= 64:</pre>
                    return 'adult'
               return 'retired'
           # Lakukan pengujian untuk melihat apakah fungsi bekerja atau tidak
In [52]:
           print(age group(9))
           print(age_group(19))
           print(age group(20))
           print(age_group(65))
          children
          teenager
          adult
          retired
In [53]:
          # Buatlah kolom baru berdasarkan fungsi
           df['age_group'] = df['dob_years'].apply(age_group)
In [54]:
           # Periksa bagaimana nilai di dalam kolom baru
           df.head(10)
                                                  education education_id family_status family_status_id gend
Out[54]:
              children days_employed dob_years
                                                  bachelor's
           0
                    1
                          8437.673028
                                            42.0
                                                                       0
                                                                               married
                                                                                                     0
                                                     degree
                                                  secondary
           1
                    1
                          4024.803754
                                            36.0
                                                                       1
                                                                               married
                                                                                                     0
                                                  education
                                                  secondary
           2
                    0
                          5623.422610
                                            33.0
                                                                       1
                                                                               married
                                                                                                     0
                                                  education
                                                  secondary
           3
                    3
                          4124.747207
                                            32.0
                                                                       1
                                                                               married
                                                                                                     0
                                                  education
                                                  secondary
                                                                                   civil
           4
                    0
                        340266.072047
                                            53.0
                                                                       1
                                                                                                     1
                                                  education
                                                                            partnership
                                                  bachelor's
                                                                                   civil
           5
                    0
                           926.185831
                                            27.0
                                                                       0
                                                                                                     1
                                                     degree
                                                                            partnership
                                                  bachelor's
           6
                    0
                          2879.202052
                                            43.0
                                                                       0
                                                                               married
                                                                                                     0
                                                     degree
                                                  secondary
          7
                    0
                           152.779569
                                            50.0
                                                                       1
                                                                               married
                                                                                                     0
                                                  education
                                                  bachelor's
                                                                                   civil
           8
                    2
                          6929.865299
                                            35.0
                                                                       0
                                                                                                     1
                                                     degree
                                                                            partnership
                                                  secondary
           9
                    0
                          2188.756445
                                            41.0
                                                                       1
                                                                               married
                                                                                                     0
                                                  education
           # Buat tabel tanpa nilai yang hilang dan tampilkan beberapa barisnya untuk memastikan
In [55]:
           df not na = df[df['total income'].notna()].reset index(drop=True)
           df not na
```

Out[55]:	child	ren	days_employed	dob_years	education	education_id	family_status	family_status_id			
	0	1	8437.673028	42.0	bachelor's degree	0	married	0			
	1	1	4024.803754	36.0	secondary education	1	married	0			
	2	0	5623.422610	33.0	secondary education	1	married	0			
	3	3	4124.747207	32.0	secondary education	1	married	0			
	4	0	340266.072047	53.0	secondary education	1	civil partnership	1			
	•••										
	19345	1	4529.316663	43.0	secondary education	1	civil partnership	1			
	19346	0	343937.404131	67.0	secondary education	1	married	0			
	19347	1	2113.346888	38.0	secondary education	1	civil partnership	1			
	19348	3	3112.481705	38.0	secondary education	1	married	0			
	19349	2	1984.507589	40.0	secondary education	1	married	0			
	19350 rows ×	: 13	columns								
4								>			
In [56]:	<pre>mean_income_grouped = df.groupby('age_group')['total_income'].mean() median_income_grouped = df.groupby('age_group')['total_income'].median()</pre>										
	<pre>print()</pre>		ome_grouped) ncome_grouped)								
	age_group adult retired teenager Name: total	21 16	025.800588 542.650450 993.942462 come, dtype: f	loat64							
	age_group adult retired teenager Name: total	18 14	385.065 471.391 934.901 come, dtype: f	loat64							
In [57]:	mean_adult	inc	income = df[df ome = df[df['a ncome = df[df[ge_group'	== 'adul	t']['total_i	.ncome'].mean	()			
			r_income = df[ncome = df[df[

```
median retired income = df[df['age group'] == 'retired']['total income'].median()
          print('rata-rata income teenager = ', mean_teenager_income)
          print('rata-rata income adult = ', mean_adult_income)
         print('rata-rata income retired = ', mean_retired_income)
          print('median income teenager = ', median_teenager_income)
          print('median income adult = ', median_adult_income)
          print('median income retired = ', median_retired_income)
         rata-rata income teenager = 16993.942461538463
         rata-rata income adult = 27025.800587828715
         rata-rata income retired = 21542.65044987775
         median income teenager = 14934.901000000002
         median income adult = 23385.065
         median income retired = 18471.391000000003
         # Perhatikan nilai rata-rata untuk pendapatan berdasarkan faktor yang telah teridentif
In [58]:
         df.groupby('age group')['total income'].mean()
         age_group
Out[58]:
         adult
                     27025.800588
         retired
                     21542.650450
         teenager
                     16993.942462
         Name: total_income, dtype: float64
         # Perhatikan nilai median untuk pendapatan berdasarkan faktor yang telah teridentifika
In [59]:
         df.groupby('age_group')['total_income'].median()
         age_group
Out[59]:
         adult
                     23385.065
         retired
                     18471.391
                     14934.901
         teenager
         Name: total income, dtype: float64
In [60]:
         sns.boxplot(df not na['total income'])
         <AxesSubplot:xlabel='total income'>
Out[60]:
```



Karena dari distribusi datanya terdpat outlier yang sangat besar, nilai yang diambil untuk mengisi nilai yang hilang adalah median dari total_income.

```
In [61]: # Tulis fungsi yang akan kita gunakan untuk mengisi nilai yang hilang
def fill_missing_value (dataframe, agg_column, value_column):
```

```
grouped_values = dataframe.groupby(agg_column)[value_column].median().reset_index(
    size = len(grouped_values)
    for i in range(size):
        group = grouped_values[agg_column][i]
        value = grouped_values[value_column][i]
        dataframe.loc[(dataframe[agg_column]==group) & (dataframe[value_column].isna()
        return dataframe
In [62]: # Memeriksa bagaimana nilai di dalam kolom baru
df.head(20)
```

Out[62]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gen
0	1	8437.673028	42.0	bachelor's degree	0	married	0	
1	1	4024.803754	36.0	secondary education	1	married	0	
2	0	5623.422610	33.0	secondary education	1	married	0	
3	3	4124.747207	32.0	secondary education	1	married	0	
4	0	340266.072047	53.0	secondary education	1	civil partnership	1	
5	0	926.185831	27.0	bachelor's degree	0	civil partnership	1	
6	0	2879.202052	43.0	bachelor's degree	0	married	0	
7	0	152.779569	50.0	secondary education	1	married	0	
8	2	6929.865299	35.0	bachelor's degree	0	civil partnership	1	
9	0	2188.756445	41.0	secondary education	1	married	0	
10	2	4171.483647	36.0	bachelor's degree	0	married	0	
11	0	792.701887	40.0	secondary education	1	married	0	
12	0	NaN	65.0	secondary education	1	civil partnership	1	
13	0	1846.641941	54.0	some college	2	married	0	
14	0	1844.956182	56.0	bachelor's degree	0	civil partnership	1	
15	1	972.364419	26.0	secondary education	1	married	0	
16	0	1719.934226	35.0	secondary education	1	married	0	
17	0	2369.999720	33.0	bachelor's degree	0	civil partnership	1	
18	0	400281.136913	53.0	secondary education	1	widow / widower	2	
19	0	10038.818549	48.0	secondary education	1	divorced	3	

```
In [63]: df = df.reset_index(drop=True)
In [64]: # Terapkan fungsi tersebut ke setiap baris
df = fill_missing_value (dataframe=df, agg_column='age_group', value_column='total_incolumn='df.head(20)
In [65]: df.head(20)
```

Out[65]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gen
0	1	8437.673028	42.0	bachelor's degree	0	married	0	
1	1	4024.803754	36.0	secondary education	1	married	0	
2	0	5623.422610	33.0	secondary education	1	married	0	
3	3	4124.747207	32.0	secondary education	1	married	0	
4	0	340266.072047	53.0	secondary education	1	civil partnership	1	
5	0	926.185831	27.0	bachelor's degree	0	civil partnership	1	
6	0	2879.202052	43.0	bachelor's degree	0	married	0	
7	0	152.779569	50.0	secondary education	1	married	0	
8	2	6929.865299	35.0	bachelor's degree	0	civil partnership	1	
9	0	2188.756445	41.0	secondary education	1	married	0	
10	2	4171.483647	36.0	bachelor's degree	0	married	0	
11	0	792.701887	40.0	secondary education	1	married	0	
12	0	NaN	65.0	secondary education	1	civil partnership	1	
13	0	1846.641941	54.0	some college	2	married	0	
14	0	1844.956182	56.0	bachelor's degree	0	civil partnership	1	
15	1	972.364419	26.0	secondary education	1	married	0	
16	0	1719.934226	35.0	secondary education	1	married	0	
17	0	2369.999720	33.0	bachelor's degree	0	civil partnership	1	
18	0	400281.136913	53.0	secondary education	1	widow / widower	2	
19	0	10038.818549	48.0	secondary education	1	divorced	3	

```
# Periksa apakah kita mendapatkan kesalahan
In [66]:
         df.isna().sum()
         children
                                0
Out[66]:
         days employed
                             2035
         dob_years
                                0
         education
                                0
         education id
         family status
                                0
         family_status_id
                                0
         gender
         income type
                                0
         debt
         total income
                                0
                                0
         purpose
         age_group
                                0
         dtype: int64
         # Periksa jumlah entri di kolom
In [68]:
         df.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 21385 entries, 0 to 21384
         Data columns (total 13 columns):
              Column
                                Non-Null Count Dtype
         ---
              _____
                                _____
          0
              children
                                21385 non-null int64
          1
              days_employed
                                19350 non-null float64
          2
              dob years
                                21385 non-null float64
          3
              education
                                21385 non-null object
              education_id
          4
                                21385 non-null int64
              family_status
          5
                                21385 non-null object
          6
              family status id 21385 non-null int64
          7
                                21385 non-null object
              gender
          8
              income_type
                                21385 non-null object
          9
              debt
                                21385 non-null int64
             total_income
                                21385 non-null float64
          10
          11
              purpose
                                21385 non-null object
                                21385 non-null object
          12 age group
         dtypes: float64(3), int64(4), object(6)
         memory usage: 2.1+ MB
```

Memperbaiki nilai di days employed

```
# Distribusi median dari `days_employed` berdasarkan parameter yang Anda identifikasi
median_days_employed_work = df.groupby('income_type')['days_employed'].median()
median_days_employed_age = df.groupby('age_group')['days_employed'].median()

median_business_day = df[df['income_type'] == 'business']['days_employed'].median()
median_civil_day = df[df['income_type'] == 'civil servant']['days_employed'].median()
median_employee_day = df[df['income_type'] == 'employee']['days_employed'].median()
median_entrepreneur_day = df[df['income_type'] == 'entrepreneur']['days_employed'].median()
median_paternity_day = df[df['income_type'] == 'paternity / maternity leave']['days_em
median_retiree_day = df[df['income_type'] == 'retiree']['days_employed'].median()
median_student_day = df[df['income_type'] == 'student']['days_employed'].median()
median_unemployed_day = df[df['income_type'] == 'unemployed']['days_employed'].median()
```

```
print(median days employed work)
          print()
          print(median days employed age)
          print('Median days employed untuk business adalah:', median business day)
          print('Median days employed untuk civil servant adalah:',median civil day)
          print('Median days employed untuk employee adalah:',median employee day)
          print('Median days employed untuk entrepreneur adalah:',median entrepreneur day)
          print('Median days employed untuk paternity/maternity adalah:',median_paternity_day)
          print('Median days employed untuk retiree adalah:',median retiree day)
          print('Median days employed untuk student adalah:',median student day)
          print('Median days employed untuk unemployed adalah:',median unemployed day)
         income type
         business
                                           1546.333214
         civil servant
                                           2689.368353
                                           1574.202821
         employee
                                           520.848083
         entrepreneur
         paternity / maternity leave
                                           3296.759962
         retiree
                                         365213.306266
         student
                                            578.751554
                                         366413.652744
         unemployed
         Name: days employed, dtype: float64
         age_group
         adult
                       2051.458422
         retired
                     360304.232308
                        724.492610
         teenager
         Name: days employed, dtype: float64
         Median days employed untuk business adalah: 1546.3332141566746
         Median days employed untuk civil servant adalah: 2689.3683533043886
         Median days employed untuk employee adalah: 1574.2028211070854
         Median days employed untuk entrepreneur adalah: 520.8480834953765
         Median days employed untuk paternity/maternity adalah: 3296.7599620220594
         Median days employed untuk retiree adalah: 365213.3062657312
         Median days employed untuk student adalah: 578.7515535382181
         Median days employed untuk unemployed adalah: 366413.65274420456
         # Distribusi rata-rata dari `days employed` berdasarkan parameter yang Anda identifika
In [70]:
         mean days employed work = df.groupby('income type')['days employed'].mean()
         mean days employed age = df.groupby('age group')['days employed'].mean()
          print(mean days employed work)
          print()
          print(mean days employed age)
```

```
income_type
business
                                  2111.470404
civil servant
                                  3399.896902
employee
                                  2326.499216
entrepreneur
                                   520.848083
paternity / maternity leave
                                  3296.759962
retiree
                                365003.491245
student
                                   578.751554
unemployed
                                366413.652744
```

Name: days employed, dtype: float64

age_group

adult 56047.219081 retired 314080.528722 teenager 633.678086

Name: days_employed, dtype: float64

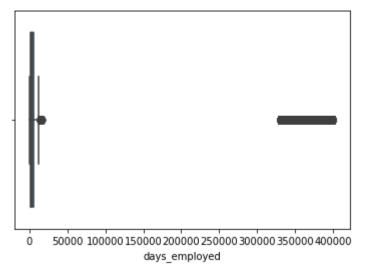
```
In [71]: df_days_not_na = df[df['days_employed'].notna()].reset_index(drop=True)

df_days_not_na
```

ut[71]:		children	days_employed	dob_years	education	education_id	family_status	family_status_id
	0	1	8437.673028	42.0	bachelor's degree	0	married	0
	1	1	4024.803754	36.0	secondary education	1	married	0
	2	0	5623.422610	33.0	secondary education	1	married	0
	3	3	4124.747207	32.0	secondary education	1	married	0
	4	0	340266.072047	53.0	secondary education	1	civil partnership	1
	•••							
	19345	1	4529.316663	43.0	secondary education	1	civil partnership	1
	19346	0	343937.404131	67.0	secondary education	1	married	0
	19347	1	2113.346888	38.0	secondary education	1	civil partnership	1
	19348	3	3112.481705	38.0	secondary education	1	married	0
	19349	2	1984.507589	40.0	secondary education	1	married	0

19350 rows × 13 columns

```
In [72]: sns.boxplot(df_days_not_na['days_employed'])
Out[72]: <AxesSubplot:xlabel='days_employed'>
```



Yang akan digunakan untuk mengisi nilai yang hilang adalah median, karena outlier pada days_employed cukup besar.

Untuk fungsi yang digunakan dalam mengisi nilai yang hilang di days_employed, akan digunakan fungsi yang sama seperti pada saat mengisi total_income yang hilang, yaitu fungsi fill_missing_value

```
In [75]: # Terapkan fungsi ke income_type
    df = fill_missing_value (dataframe=df, agg_column='income_type', value_column='days_en
In [76]: # Periksa apakah fungsi Anda bekerja
    df.head(20)
```

Out[76]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gen
0	1	8437.673028	42.0	bachelor's degree	0	married	0	
1	1	4024.803754	36.0	secondary education	1	married	0	
2	0	5623.422610	33.0	secondary education	1	married	0	
3	3	4124.747207	32.0	secondary education	1	married	0	
4	0	340266.072047	53.0	secondary education	1	civil partnership	1	
5	0	926.185831	27.0	bachelor's degree	0	civil partnership	1	
6	0	2879.202052	43.0	bachelor's degree	0	married	0	
7	0	152.779569	50.0	secondary education	1	married	0	
8	2	6929.865299	35.0	bachelor's degree	0	civil partnership	1	
9	0	2188.756445	41.0	secondary education	1	married	0	
10	2	4171.483647	36.0	bachelor's degree	0	married	0	
11	0	792.701887	40.0	secondary education	1	married	0	
12	0	365213.306266	65.0	secondary education	1	civil partnership	1	
13	0	1846.641941	54.0	some college	2	married	0	
14	0	1844.956182	56.0	bachelor's degree	0	civil partnership	1	
15	1	972.364419	26.0	secondary education	1	married	0	
16	0	1719.934226	35.0	secondary education	1	married	0	
17	0	2369.999720	33.0	bachelor's degree	0	civil partnership	1	
18	0	400281.136913	53.0	secondary education	1	widow / widower	2	
19	0	10038.818549	48.0	secondary education	1	divorced	3	

```
df['days_employed'].describe()
                   21385.000000
         count
Out[78]:
         mean
                   66862.289754
         std
                  139033.378265
         min
                      24.141633
         25%
                    1019.604773
         50%
                    1999.778276
         75%
                    5309.423719
                  401755.400475
         max
         Name: days_employed, dtype: float64
         df = df.round({'days employed': 0}).reset index(drop=True)
In [79]:
In [80]:
         df.isna().sum()
         children
                              0
Out[80]:
         days_employed
                              0
         dob_years
                              0
         education
         education id
                              0
         family_status
                              0
         family status id
         gender
                              9
         income_type
                              0
         debt
                              0
         total_income
                              0
         purpose
                              0
                              0
         age group
         dtype: int64
         # Periksa entri di semua kolom - pastikan kita memperbaiki semua nilai yang hilang
In [81]:
         df.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 21385 entries, 0 to 21384
         Data columns (total 13 columns):
          #
              Column
                                Non-Null Count Dtype
          ---
          0
              children
                                 21385 non-null int64
          1
              days_employed
                                21385 non-null float64
          2
                                21385 non-null float64
              dob years
          3
              education
                                 21385 non-null object
          4
              education_id
                                21385 non-null int64
          5
              family_status
                                21385 non-null object
          6
              family status id 21385 non-null int64
          7
              gender
                                 21385 non-null object
          8
                                 21385 non-null object
              income_type
          9
              debt
                                 21385 non-null int64
          10
              total_income
                                 21385 non-null float64
              purpose
                                 21385 non-null object
              age_group
                                 21385 non-null object
         dtypes: float64(3), int64(4), object(6)
         memory usage: 2.1+ MB
```

Pengkategorian Data

In [82]: df.head(20)

Out[82]:

	children	days_employed	dob_years	education	education_id	family_status	family_status_id	gen
0	1	8438.0	42.0	bachelor's degree	0	married	0	
1	1	4025.0	36.0	secondary education	1	married	0	
2	0	5623.0	33.0	secondary education	1	married	0	
3	3	4125.0	32.0	secondary education	1	married	0	
4	0	340266.0	53.0	secondary education	1	civil partnership	1	
5	0	926.0	27.0	bachelor's degree	0	civil partnership	1	
6	0	2879.0	43.0	bachelor's degree	0	married	0	
7	0	153.0	50.0	secondary education	1	married	0	
8	2	6930.0	35.0	bachelor's degree	0	civil partnership	1	
9	0	2189.0	41.0	secondary education	1	married	0	
10	2	4171.0	36.0	bachelor's degree	0	married	0	
11	0	793.0	40.0	secondary education	1	married	0	
12	0	365213.0	65.0	secondary education	1	civil partnership	1	
13	0	1847.0	54.0	some college	2	married	0	
14	0	1845.0	56.0	bachelor's degree	0	civil partnership	1	
15	1	972.0	26.0	secondary education	1	married	0	
16	0	1720.0	35.0	secondary education	1	married	0	
17	0	2370.0	33.0	bachelor's degree	0	civil partnership	1	
18	0	400281.0	53.0	secondary education	1	widow / widower	2	
19	0	10039.0	48.0	secondary education	1	divorced	3	

```
# Tampilkan nilai data yang dipilih untuk pengkategorian
In [83]:
          df.groupby('purpose')['purpose'].count()
         purpose
Out[83]:
         building a property
                                                       618
         building a real estate
                                                       622
         buy commercial real estate
                                                       658
         buy real estate
                                                       617
         buy residential real estate
                                                       605
         buying a second-hand car
                                                       477
         buying my own car
                                                       505
         buying property for renting out
                                                       649
         car
                                                       493
                                                       460
         car purchase
                                                       478
         cars
         construction of own property
                                                       635
         education
                                                       447
         getting an education
                                                       441
         getting higher education
                                                       426
         going to university
                                                       496
         having a wedding
                                                       759
                                                       645
         housing
         housing renovation
                                                       604
         housing transactions
                                                       651
         profile education
                                                       436
         property
                                                       632
         purchase of a car
                                                       455
         purchase of my own house
                                                       620
         purchase of the house
                                                       645
         purchase of the house for my family
                                                       635
         real estate transactions
                                                       674
         second-hand car purchase
                                                       483
         supplementary education
                                                       458
         to become educated
                                                       404
         to buy a car
                                                       470
         to get a supplementary education
                                                       445
         to have a wedding
                                                       757
         to own a car
                                                       476
         transactions with commercial real estate
                                                       649
         transactions with my real estate
                                                       624
         university education
                                                       451
         wedding ceremony
                                                       785
         Name: purpose, dtype: int64
         # Periksa nilai unik
In [84]:
          sorted(df['purpose'].unique())
```

```
['building a property',
Out[84]:
           'building a real estate',
           'buy commercial real estate',
           'buy real estate',
           'buy residential real estate',
           'buying a second-hand car',
           'buying my own car',
           'buying property for renting out',
           'car',
           'car purchase',
           'cars',
           'construction of own property',
           'education',
           'getting an education',
           'getting higher education',
           'going to university',
           'having a wedding',
           'housing',
           'housing renovation',
           'housing transactions',
           'profile education',
           'property',
           'purchase of a car',
           'purchase of my own house',
           'purchase of the house',
           'purchase of the house for my family',
           'real estate transactions',
           'second-hand car purchase',
           'supplementary education',
           'to become educated',
           'to buy a car',
           'to get a supplementary education',
           'to have a wedding',
           'to own a car',
           'transactions with commercial real estate',
           'transactions with my real estate',
           'university education',
           'wedding ceremony']
```

Kelompok utama yang teridentifikasi berdasarkan nilai uniknya adalah pada kolom 'purpose' yang mana terbagi menjadi 4 kategori yaitu property real estate, cars, education, dan wedding.

```
# Mari kita tulis sebuah fungsi untuk mengategorikan data berdasarkan topik umum
In [85]:
         def categorize purpose(row):
             if 'car' in row:
                  return 'car'
             elif 'hous' in row or 'prop' in row or 'real est' in row:
                  return 'real estate'
             elif 'wedd' in row:
                 return 'wedding'
              elif 'educ' in row or 'uni' in row:
                  return 'education'
             else:
                  return 'Unidentified'
         # Buat kolom yang memuat kategori dan hitung nilainya
         df['category'] = df['purpose'].apply(categorize purpose)
          print(df.groupby('category')['category'].count())
```

```
category
                          4297
         car
         education
                          4004
                         10783
         real estate
         wedding
                          2301
         Name: category, dtype: int64
         # Lihat semua data numerik di kolom yang Anda pilih untuk pengkategorian
In [87]:
          print(df.groupby('age_group')['total_income'].mean())
          print(df['total income'].mean())
         age_group
         adult
                      26677.353801
         retired
                      21287.859868
         teenager
                      16846.868071
         Name: total_income, dtype: float64
         26446.114362450317
         # Dapatkan kesimpulan statistik untuk kolomnya
In [88]:
          df['total_income'].describe()
                    21385.000000
         count
Out[88]:
         mean
                    26446.114362
         std
                    15710.202614
         min
                     3306.762000
         25%
                    17188.530000
         50%
                   23385.065000
         75%
                   31368.208000
                   362496.645000
         max
         Name: total income, dtype: float64
         Rentang yang akan digunakan adalah rata-rata dari total_income untuk mengelompokkan
         kategori pendapatan berdasarkan total_income dari para nasabah.
         # Buat fungsi yang melakukan pengkategorian menjadi kelompok numerik yang berbeda berd
In [89]:
          def rate income (total income):
              if total income < 21000:</pre>
                  return 'low'
              elif 21000 <= total_income <= 31000:</pre>
                  return 'average'
              return 'high'
         # Buat kolom yang memuat kategori
          df['rate_income'] = df['total_income'].apply(rate_income)
In [91]: # Hitung setiap nilai kategori untuk melihat pendistribusiannya
          df.groupby('rate income')['total income'].count()
         rate income
Out[91]:
         average
                     7725
         high
                     5500
         low
                     8160
```

Memeriksa hipotesis

Name: total_income, dtype: int64

Apakah terdapat korelasi antara memiliki anak dengan melakukan pelunasan tepat

waktu?

```
# Periksa data anak dan data pelunasan tepat waktu
In [92]:
         # Hitung gagal bayar berdasarkan jumlah anak
         pivot table children = df.pivot table(index='children', columns= 'debt', values='days
         print(pivot table children)
         debt
                         0
         children
         0
                   12972.0 1063.0
         1
                    4400.0
                            445.0
         2
                    1923.0 202.0
         3
                     303.0
                            27.0
         4
                      37.0
                               4.0
         5
                       9.0
                               NaN
```

Kesimpulan

Dari hasil diatas untuk kemungkinan gagal bayar banyak dialami oleh nasabah yang memiliki 1 anak, nilainya terus menurun jika dilihat secara berurutan dari jumlah anak terbanyak. Dari hal ini hipotesis kita untuk jumlah anak semakin banyak mengakibatkan nasabah gagal membayar tepat waktu adalah salah, hasil yang didapat sebaliknya dengan hipotesis awal

Apakah terdapat korelasi antara status keluarga dengan pelunasan tepat waktu?

```
In [93]:
         # Periksa data status keluarga dan pelunasan tepat waktu
          # Hitung gagal bayar berdasarkan status keluarga
          pivot_table_family = df.pivot_table(index='family_status', columns= 'debt', values='da
          print(pivot_table_family)
         debt
         family_status
                             3737 388
         civil partnership
         divorced
                             1110
                                    85
         married
                            11369
                                   931
         unmarried
                             2533 274
         widow / widower
                              895
                                    63
```

Kesimpulan

Nasabah yang gagal membayar tepat waktu paling banyak adalah yang memiliki family_status married, dan paling sedikit adalah widow/widower. Hasil ini juga sesuai dengan hipotesis di awal bahwa nasabah dengan family_status married akan sulit membayar tepat waktu

Apakah terdapat korelasi antara tingkat pendapatan dengan membayar kembali tepat waktu?

```
In [94]: # Periksa data tingkat pendapatan dan pelunasan tepat waktu

# Hitung gagal bayar berdasarkan tingkat pendapatan
pivot_table_rate = df.pivot_table(index='rate_income', columns= 'debt', values='days_6
print(pivot_table_rate)
```

debt	0	1
rate_income		
average	7041	684
high	5104	396
low	7499	661

Kesimpulan

Sesuai dengan pengkategorian tingkat pendapatan, untuk nasabah yang berada pada tingkat average income paling banyak gagal membayar tepat waktu, diikuti oleh low income dengan selisih yang tidak begitu jauh, dan paling sedikit adalah kategori high income. Hasil ini tidak sesuai dengan hipotesis kita, walaupun hasil yang didapat antara jumlah nasabah dengan low income dan average sangatlah sedikit.

Bagaimana tujuan kredit memengaruhi tingkat gagal bayar?

Kesimpulan

Kebanyakan nasabah yang gagal membayar tepat waktu memiliki tujuan ke arah real estate dan yang paling sedikit adalah untuk pernikahan. Hasil ini sesuai dengan hipotesis di awal, nasabah dengan tujuan peminjaman untuk tempat tinggal memiliki resiko gagal bayar tepat waktu.

Kesimpulan umum

Kesimpulan yang didapat dari file credit_scoring_eng adalah ada beberapa yang data yang nilainya hilang pada kolom days_employed, total_income, dan dob_years. Selain itu penulisan yang tidak seragam pada kolom education, nilai yang bermasalah pada kolom days_employed, dan adanya duplikasi data.

Permasalahan tersebut diatasi dengan menyamakan ukuran karakter huruf pada kolom yang nilainya berbeda, mengisi nilai yang hilang menggunakan median dari nilai yang terdapat pada kolom nilai yang hilang, menghapus data yang 'unidentified', dan menghapus duplikat yang terdeteksi pada tabel.

Setelah memperbaiki semua permasalahan yang ada, nasabah yang memiliki potensi gagal bayar adalah nasabah yang mengajukan peminjaman untuk kategori real estate, nasabah yang memiliki rate_income average, nasabah yang family_status married, atau nasabah yang memiliki jumlah anak 1.